

KI-Grundbegriffe

Die wichtigsten Konzepte des Workshops in einfacher Sprache – mit Beispielen und Abgrenzungen.

Vom Modell zum Agenten

Modell

Der sprachliche „Motor“. Es erzeugt Antworten und kann entscheiden, welches Werkzeug gebraucht wird.

Harness

Die Software-Hülle um das Modell. Sie verbindet Kontext, Werkzeuge, Speicher, Regeln und Freigaben.

Agent

Modell plus Harness plus Ziel. Der Agent kann mehrere kontrollierte Schritte planen und ausführen.

Merksatz: Modell = Motor. Harness = Fahrzeug mit Lenkrad und Bremsen. Agent = Fahrzeug, das einen Auftrag abarbeitet.

Tool Use: Sprache wird ausführbar

- 1 Sie fragen: „Was sind 17,5 % von 1.849,90 €?“
- 2 Das Modell erzeugt einen strukturierten Aufruf: `calculator({ expression: "1849.90 * 0.175" })`.
- 3 Der Taschenrechner liefert exakt 323.7325.
- 4 Die KI formuliert verständlich: **323,73 €**.

Das Modell muss die Rechnung nicht erraten. Es nutzt ein spezialisiertes Werkzeug und verarbeitet dessen Ergebnis.

Quantisierung

Quantisierung speichert die Zahlen eines Modells mit weniger Genauigkeit. Das Modell wird dadurch kleiner und benötigt weniger RAM oder VRAM.

FP16

Viele feine Zahlenabstufungen, mehr Speicher, hohe Genauigkeit.

Q4

Ungefähr 4-Bit-Darstellung, deutlich weniger Speicher, meist noch gut nutzbare Qualität.

Bildvergleich: Ein leicht unschärferes Foto braucht weniger Daten. Das Motiv bleibt trotzdem erkennbar. Ebenso bleiben viele Fähigkeiten eines quantisierten Modells nutzbar, obwohl feine Details verloren gehen können.

RAG und Second Brain

RAG = Retrieval-Augmented Generation, deutsch etwa „abrufgestützte Generierung“.

1

Eine Frage kommt an.

2

Das System sucht passende Stellen in Dokumenten.

3

Diese Fundstellen werden in den Kontext gelegt.

4

Das Modell antwortet auf Basis der gefundenen Quellen.

Beispiel: „Welche Kündigungsfrist steht in unserem Vertrag?“ RAG findet den Vertragsabsatz; das Modell erklärt ihn und nennt die Quelle.

Begriff	Bedeutung
Second Brain	Die organisierte persönliche oder betriebliche Wissenssammlung.
RAG	Die Technik, die daraus passende Stellen sucht und dem Modell zuführt.
Memory	Gespeicherte Präferenzen, Entscheidungen oder Fakten für spätere Sitzungen.

Skill, Command und MCP

Begriff	Einfache Erklärung	Beispiel
Skill	Wiederverwendbare Arbeitsanleitung mit Wissen und Prüfschritten.	„Aktuelle News mit Primärquellen prüfen“
Command / Befehl	Kurzer gespeicherter Starter, der einen Skill aufruft.	<code>/news-radar</code>
MCP	Model Context Protocol: offener Anschlussstandard für KI-Werkzeuge und Daten.	Wie USB-C für Browser, Dateien, Datenbanken oder Kalender

Abkürzungen

Kürzel	Ausgeschrieben	Bedeutung
AI / KI	Artificial Intelligence / Künstliche Intelligenz	Oberbegriff für lernende oder schlussfolgernde Systeme
LLM	Large Language Model	Großes Sprachmodell
RAG	Retrieval-Augmented Generation	Antworten mit zuvor abgerufenen Quellen
MCP	Model Context Protocol	Standardisierte Verbindung zu Tools und Daten
API	Application Programming Interface	Programmierschnittstelle
OAuth	Open Authorization	Anmeldung und begrenzte Zugriffsfreigabe
TTS	Text to Speech	Sprachausgabe aus Text
GGUF	Modell-Dateiformat	Häufig für lokale, quantisierte Modelle
RAM / VRAM	Arbeits- / Grafikspeicher	Begrenzt Größe und Geschwindigkeit lokaler Modelle
Q4	ungefähr 4-Bit-Quantisierung	Kleineres Modell mit möglichem Qualitätsverlust