

Lokale KI mit LM Studio

Rechner prüfen, Modell auswählen, lokalen Server starten und mit Hermes verbinden.

1. Hardware mit Hermes prüfen

Hilf mir bei der Wahl eines lokalen LLM für LM Studio.

Ermittle ausschließlich lesend:

- Betriebssystem und Architektur,
- CPU,
- installierten RAM,
- GPU-Modell,
- dedizierten und gemeinsam genutzten Grafikspeicher,
- freien Speicherplatz,
- relevante Treiberinformationen.

Frage danach nach meinen Aufgaben, gewünschter Geschwindigkeit, Kontextlänge und Datenschutzanforderungen.

Empfiehle drei Optionen:

1. sicher und schnell,
2. ausgewogen,
3. experimentell.

Nenne jeweils Modellgröße, Quantisierung, erwartete Grenzen und Speicherbedarf.

Installiere oder lade noch nichts herunter.

Wichtig: Hardwareangaben des Herstellers sind nur der Ausgangspunkt. Auf dem tatsächlichen Workshop-Gerät prüfen.

2. LM Studio installieren

Windows

- 1 Offiziellen Installer von lmstudio.ai laden.
- 2 Installieren und starten.
- 3 In Discover ein instruct-fähiges GGUF-Modell wählen.

Linux

- 1 Aktuelles offizielles Linux-Paket laden.
- 2 Ausführbar machen oder distributionsgerecht installieren.
- 3 App starten und Modell laden.

Aktuelle Anforderungen: [LM Studio system requirements](#). Derzeit werden 16 GB RAM und 4 GB dedizierter VRAM empfohlen.

3. Modell auswählen

Profil	Startpunkt	Typische Aufgabe
Sicher	3B–7B, Q4	Klassifikation, Zusammenfassung, Extraktion
Ausgewogen	7B–14B, Q4	Schreiben, einfache Analyse, begrenzte Tools
Experimentell	größer / längerer Kontext	Nur wenn Speicher und Geschwindigkeit reichen

Tool-Aufrufe separat testen: Ein gutes Chatmodell ist nicht automatisch ein guter Agentenmotor.

4. Local Server starten

- 1 Modell vollständig laden.
- 2 Developer-Bereich öffnen.
- 3 Local Server starten.
- 4 Adresse notieren, standardmäßig häufig `http://127.0.0.1:1234/v1`.

[Offizielle Server-Dokumentation](#)

5. Hermes verbinden

```
Provider type: OpenAI-compatible  
Base URL: http://127.0.0.1:1234/v1  
API key: lm-studio  
Model: exakt der in LM Studio angezeigte Modellname
```

- ☐ Zuerst einfacher Chat-Test.
- ☐ Dann strukturierte Ausgabe testen.
- ☐ Erst danach Datei- oder Toolzugriff testen.
- ☐ Bei Fehlern Modellname, Serverstatus und URL prüfen.

6. Fairer Lokal-/Cloud-Test

```
Fasse das folgende fiktive Sitzungsprotokoll in genau 5 Punkten zusammen.  
Extrahiere Entscheidungen und nächste Schritte als Markdown-Tabelle.  
Erfinde nichts. Markiere fehlende Verantwortliche mit „nicht angegeben“.  
Nenne am Ende zwei Unsicherheiten im Ausgangstext.
```

Kriterium	Lokal	Cloud
Zeit bis zur Antwort		
Korrekte Extraktion		
Format eingehalten		
Halluzinationen		
Datenschutz / Kosten		