

# KI-Grundbegriffe

Die wichtigsten Konzepte des Workshops in einfacher Sprache – mit Beispielen und Abgrenzungen.

## Vom Modell zum Agenten

### Modell

Der sprachliche „Motor“. Es erzeugt Antworten und kann entscheiden, welches Werkzeug gebraucht wird.

### Harness

Die Software-Hülle um das Modell. Sie verbindet Kontext, Werkzeuge, Speicher, Regeln und Freigaben.

### Agent

Modell plus Harness plus Ziel. Der Agent kann mehrere kontrollierte Schritte planen und ausführen.

**Merksatz:** Modell = Motor. Harness = Fahrzeug mit Lenkrad und Bremsen. Agent = Fahrzeug, das einen Auftrag abarbeitet.

## Tool Use: Sprache wird ausführbar

**1**

Sie fragen: „Was sind 17,5 % von 1.849,90 €?“

**2**

Das Modell erzeugt einen strukturierten Aufruf: `calculator({ expression: "1849.90 * 0.175" })`.

**3**

Der Taschenrechner liefert exakt 323.7325.

**4**

Die KI formuliert verständlich: **323,73 €**.

Das Modell muss die Rechnung nicht erraten. Es nutzt ein spezialisiertes Werkzeug und verarbeitet dessen Ergebnis.

## Quantisierung

Quantisierung speichert die Zahlen eines Modells mit weniger Genauigkeit. Das Modell wird dadurch kleiner und benötigt weniger RAM oder VRAM.

### FP16

Viele feine Zahlenabstufungen, mehr Speicher, hohe Genauigkeit.

### Q4

Ungefähr 4-Bit-Darstellung, deutlich weniger Speicher, meist noch gut nutzbare Qualität.

**Bildvergleich:** Ein leicht unschärferes Foto braucht weniger Daten. Das Motiv bleibt trotzdem erkennbar. Ebenso bleiben viele Fähigkeiten eines quantisierten Modells nutzbar, obwohl feine Details verloren gehen können.

## RAG und Second Brain

**RAG = Retrieval-Augmented Generation**, deutsch etwa „abrufgestützte Generierung“.

1

Eine Frage kommt an.

2

Das System sucht passende Stellen in Dokumenten.

3

Diese Fundstellen werden in den Kontext gelegt.

4

Das Modell antwortet auf Basis der gefundenen Quellen.

**Beispiel:** „Welche Kündigungsfrist steht in unserem Vertrag?“ RAG findet den Vertragsabsatz; das Modell erklärt ihn und nennt die Quelle.

| Begriff      | Bedeutung                                                                   |
|--------------|-----------------------------------------------------------------------------|
| Second Brain | Die organisierte persönliche oder betriebliche Wissenssammlung.             |
| RAG          | Die Technik, die daraus passende Stellen sucht und dem Modell zuführt.      |
| Memory       | Gespeicherte Präferenzen, Entscheidungen oder Fakten für spätere Sitzungen. |

## Skill, Command und MCP

| Begriff             | Einfache Erklärung                                                                   | Beispiel                                                  |
|---------------------|--------------------------------------------------------------------------------------|-----------------------------------------------------------|
| Skill               | Wiederverwendbare Arbeitsanleitung mit Wissen und Prüfschritten.                     | „Aktuelle News mit Primärquellen prüfen“                  |
| Command /<br>Befehl | Kurzer gespeicherter Starter, der einen Skill aufruft.                               | <code>/news-radar</code>                                  |
| MCP                 | <b>Model Context Protocol:</b> offener Anschlussstandard für KI-Werkzeuge und Daten. | Wie USB-C für Browser, Dateien, Datenbanken oder Kalender |

# Abkürzungen

| Kürzel     | Ausgeschrieben                                   | Bedeutung                                              |
|------------|--------------------------------------------------|--------------------------------------------------------|
| AI / KI    | Artificial Intelligence / Künstliche Intelligenz | Oberbegriff für lernende oder schlussfolgernde Systeme |
| LLM        | Large Language Model                             | Großes Sprachmodell                                    |
| RAG        | Retrieval-Augmented Generation                   | Antworten mit zuvor abgerufenen Quellen                |
| MCP        | Model Context Protocol                           | Standardisierte Verbindung zu Tools und Daten          |
| API        | Application Programming Interface                | Programmierschnittstelle                               |
| OAuth      | Open Authorization                               | Anmeldung und begrenzte Zugriffsfreigabe               |
| TTS        | Text to Speech                                   | Sprachausgabe aus Text                                 |
| GGUF       | Modell-Dateiformat                               | Häufig für lokale, quantisierte Modelle                |
| RAM / VRAM | Arbeits- / Grafikspeicher                        | Begrenzt Größe und Geschwindigkeit lokaler Modelle     |
| Q4         | ungefähr 4-Bit-Quantisierung                     | Kleineres Modell mit möglichem Qualitätsverlust        |

# Hermes Desktop Quickstart

Direkte Installation für Windows und Linux. Docker ist optional und wird im Kernworkshop nicht benötigt.

## Vorbereitung

- ☐ Aktuelles Windows 11 oder unterstützte Linux-Distribution.
- ☐ Stabile Internetverbindung für Download und Cloud-Modelle.
- ☐ Mindestens 5 GB freier Speicher für App, Cache und Übungsdateien.
- ☐ Für den Einstieg: Nous-Portal-Konto oder unterstütztes ChatGPT-Codex-/Grok-Abo.

Offizielle Dokumentation: [Installation](#) · [Quickstart](#)

## Windows: Desktop-Installer oder PowerShell

**Empfohlen für Einsteiger:** Den signierten Hermes-Desktop-Installer über die [offizielle Installationsseite](#) laden und ausführen.

### Alternative mit konkreten Befehlen

PowerShell ohne Administratorrechte öffnen:

```
iex (irm https://hermes-agent.nousresearch.com/install.ps1)
```

Nach Abschluss alle PowerShell-Fenster schließen, ein neues öffnen und prüfen:

```
Get-Command hermes  
hermes --version  
hermes desktop
```

Für den schnellen Start mit Nous Portal:

```
hermes setup --portal
```

**1** Nur die offizielle URL verwenden und Sicherheitsdialoge aufmerksam prüfen.

**2** Hermes Desktop starten und einen separaten Workshop-Ordner wählen, z. B. Documents\AI-OS-Workshop.

**3** Zuerst eine harmlose Textfrage ohne Datei- oder Toolzugriff testen.

**PATH-Hinweis:** Wenn `hermes` nach der Installation nicht gefunden wird, ein neues Terminal öffnen. Die native Installation liegt standardmäßig unter `%LOCALAPPDATA%\hermes`.

## Linux: Hermes Desktop installieren

Die folgenden Wege sind für Debian/Ubuntu und Fedora formuliert. Sie installieren die von Hermes dokumentierten Voraussetzungen, Hermes Agent und anschließend die Desktop-App.

### 1a. Voraussetzungen unter Debian/Ubuntu

```
sudo apt update
sudo apt install -y git curl xz-utils build-essential
```

### 1b. Voraussetzungen unter Fedora

```
sudo dnf install -y git curl xz gcc-c++ make
```

Alternativ installiert `sudo dnf group install -y "Development Tools"` die vollständige Fedora-Entwicklungswerkzeuggruppe.

## 2. Hermes Agent installieren

```
curl -fsSL https://hermes-agent.nousresearch.com/install.sh | bash
```

## 3. Shell neu laden und Installation prüfen

```
source ~/.bashrc
hermes --version
hermes doctor
```

Bei Zsh stattdessen `source ~/.zshrc` verwenden.

## 4. Hermes Desktop bauen und starten

```
hermes desktop
```

Der erste Start kann länger dauern, weil die Desktop-Abhängigkeiten installiert und die Electron-App für das lokale System gebaut werden.

## 5. Nous Portal verbinden

```
hermes setup --portal
```

**1** Nur einen separaten Workshop-Arbeitsordner freigeben.

**2** Zuerst Chat und Modellverbindung testen.

**3** Danach Datei- und Toolzugriffe schrittweise aktivieren.

**Andere Distributionen:** Paketnamen unterscheiden sich. Das Installationsskript unterstützt weitere glibc-basierte Distributionen, aber die aktuelle [Plattformmatrix](#) und [Installationsanleitung](#) haben Vorrang.

Befehle gegen die offizielle Hermes-Dokumentation und den offiziellen Installer geprüft · Stand 27.07.2026.

## Provider: schnell starten

| Weg                   | Geeignet für              | Wichtiger Hinweis                                                  |
|-----------------------|---------------------------|--------------------------------------------------------------------|
| Nous Portal           | Schnellster Einstieg      | Verfügbare freie oder enthaltene Modelle im Konto prüfen.          |
| ChatGPT / Codex OAuth | Vorhandener OpenAI-Zugang | Unterstützt Codex-Modelle; nicht automatisch alle ChatGPT-Modelle. |
| Grok OAuth            | Vorhandener xAI-Zugang    | Passendes SuperGrok-/Premium+-Abo erforderlich.                    |

# Hermes richtet Hermes ein

Hilf mir, Hermes sicher und anfangergefreundlich einzurichten.

Stelle mir nacheinander höchstens 10 kurze Fragen zu:

1. meinen wichtigsten Aufgaben,
2. meinem Erfahrungsstand,
3. gewünschtem Ton und Arbeitsstil,
4. erlaubten Datenklassen,
5. Aktionen, die immer eine Freigabe benötigen,
6. bevorzugten schnellen und starken Modellen,
7. erlaubten Arbeitsordnern,
8. Inhalt meiner SOUL.md,
9. optionalem Voice-/TTS-Modus,
10. einem sicheren ersten Test.

Erkläre vor jeder Entscheidung kurz die Konsequenz.

Zeige vor jeder Dateiänderung eine Vorschau und frage mich um Freigabe.

Speichere keine Passwörter, API-Schlüssel oder Tokens in SOUL.md.

## SOUL.md – sichere Startvorlage

### # Arbeitsweise

- Antworte klar, freundlich und ohne unnötigen Fachjargon.
- Stelle Rückfragen, wenn Ziel, Datenquelle oder Freigabegrenze unklar sind.
- Trenne Fakten, Annahmen und Empfehlungen.

### # Sicherheitsgrenzen

- Nichts senden, veröffentlichen, kaufen oder löschen ohne explizite Freigabe.
- Vor Dateiänderungen Zielpfad und geplante Änderung anzeigen.
- Keine Geheimnisse oder personenbezogenen Daten dauerhaft speichern.

### # Qualitätsstandard

- Bei aktuellen Informationen Datum und Quellen nennen.
- Unsicherheit und widersprüchliche Quellen sichtbar machen.
- Nach Abschluss geänderte Dateien und offene Punkte zusammenfassen.

SOUL-Dokumentation: [Use Soul with Hermes](#)

## Voice Mode

Voice/TTS erst aktivieren, wenn Text, Modell und Freigabegrenzen zuverlässig funktionieren.

Mikrofonberechtigung bewusst vergeben und sensible Gespräche vermeiden.



# Übungen & Prompts

Jede Übung enthält Ziel, Vorbereitung, zwei Promptvarianten, Sicherheitsgrenzen und Qualitätsprüfung.

## ÜBUNG 1 · 15 MINUTEN

### Aktueller News Radar

**Ziel:** Hermes recherchiert aktuelle Entwicklungen, vergleicht Quellen und erstellt ein prüfbares Briefing.

#### Prompt A – geführt

Wir bauen gemeinsam ein aktuelles News-Briefing.

Frage mich zuerst nach:

- Thema und Zielgruppe,
- Zeitraum,
- gewünschter Länge,
- bevorzugter Sprache,
- Quellen, die ein- oder ausgeschlossen werden sollen.

Erstelle danach einen Rechercheplan. Beginne erst nach meiner Bestätigung.

Nutze mindestens 5 belastbare Quellen und bevorzuge Primärquellen.

Trenne Fakten, Einordnung und offene Fragen.

Nenne Veröffentlichungsdatum und Link je wesentlicher Aussage.

Markiere Widersprüche und Unsicherheit.

Speichere das Ergebnis als news-radar.md.

Keine Anmeldung, Nachricht, Buchung oder Zahlung ohne Freigabe.

#### Prompt B – direkt

Erstelle ein Morgenbriefing zu „KI-Agenten“ für die letzten 7 Tage.  
Zielgruppe: interessierte Selbstständige ohne technischen Hintergrund.  
Länge: maximal 700 Wörter.  
Nutze mindestens 5 belastbare Quellen, bevorzuge offizielle Ankündigungen, Dokumentationen und Originalstudien.  
Struktur:  
1. Drei wichtigste Entwicklungen  
2. Warum sie praktisch relevant sind  
3. Was noch unsicher oder umstritten ist  
4. Quellenliste mit Datum und Link  
Speichere das Ergebnis als news-radar.md.  
Erfinde keine fehlenden Angaben.

## Qualitätscheck

- ☐ Primärquellen und Daten sind sichtbar.
- ☐ Fakten und Interpretation sind getrennt.
- ☐ Widersprüche oder Unsicherheit werden genannt.
- ☐ Nur die vereinbarte Datei wurde erstellt.

## Dokumente → Entscheidungen → Aktionen

**Vorbereitung:** Einen Ordner `demo-projekt` mit ausschließlich fiktivem Protokoll, Angebot und Aufgabenliste anlegen.

### Prompt A – Extraktion

Lies ausschließlich die Dateien im Ordner `demo-projekt`.

Extrahiere:

- getroffene Entscheidungen,
- offene Punkte,
- Verantwortliche,
- Termine,
- Risiken und Widersprüche.

Erfinde keine fehlenden Daten. Kennzeichne „nicht angegeben“.

Erstelle:

1. `status.md` mit einer verständlichen Zusammenfassung,
  2. `next-actions.csv` mit Spalten Aufgabe, Verantwortlich, Termin, Quelle, Status.
- Keine Quelldatei verändern. Nichts versenden oder veröffentlichen.  
Zeige mir vor dem Schreiben eine kurze Vorschau.

### Prompt B – Management-Briefing

Erstelle aus dem Ordner `demo-projekt` ein 1-seitiges Management-Briefing.

Beginne mit „Entscheidung erforderlich“, falls Widersprüche oder fehlende Freigaben bestehen.

Nenne zu jedem Punkt die Quelldatei.

Formuliere anschließend höchstens 7 nächste Schritte nach Wirkung und Dringlichkeit.

Speichere nur `briefing.md`. Keine anderen Dateien ändern.

### Qualitätscheck

- ☐ Jede Aussage lässt sich auf eine Quelldatei zurückführen.
- ☐ Fehlende Verantwortliche oder Termine wurden nicht erfunden.
- ☐ CSV ist direkt nutzbar.
- ☐ Keine Nachricht wurde versendet.

## Agent Canvas

Wählen Sie eine kleine wiederkehrende Aufgabe. Füllen Sie Ziel, Quellen, Tools, Grenzen und Qualitätskriterien aus.

Hilf mir, aus meiner Idee einen sicheren Agenten-Workflow zu machen.

Frage nacheinander:

1. Welches konkrete Ergebnis soll entstehen?
2. Welche Eingaben und Quellen sind erlaubt?
3. Welche Werkzeuge werden benötigt?
4. Welche Aktionen sind reversibel?
5. Welche Aktionen brauchen immer Freigabe?
6. Wie erkennen wir ein gutes Ergebnis?
7. Was soll bei Unsicherheit oder Fehlern passieren?

Erstelle danach einen kompakten Agent Canvas und einen Testprompt.

Führe den Workflow noch nicht aus.

### Peer Review

- ☐ Ist das Ergebnis eindeutig?
- ☐ Ist der Zugriff minimal?
- ☐ Gibt es eine Freigabestelle?
- ☐ Ist das Verhalten bei Fehlern definiert?

# Lokale KI mit LM Studio

Rechner prüfen, Modell auswählen, lokalen Server starten und mit Hermes verbinden.

## 1. Hardware mit Hermes prüfen

Hilf mir bei der Wahl eines lokalen LLM für LM Studio.

Ermittle ausschließlich lesend:

- Betriebssystem und Architektur,
- CPU,
- installierten RAM,
- GPU-Modell,
- dedizierten und gemeinsam genutzten Grafikspeicher,
- freien Speicherplatz,
- relevante Treiberinformationen.

Frage danach nach meinen Aufgaben, gewünschter Geschwindigkeit, Kontextlänge und Datenschutzanforderungen.

Empfiehle drei Optionen:

1. sicher und schnell,
2. ausgewogen,
3. experimentell.

Nenne jeweils Modellgröße, Quantisierung, erwartete Grenzen und Speicherbedarf.

Installiere oder lade noch nichts herunter.

**Wichtig:** Hardwareangaben des Herstellers sind nur der Ausgangspunkt. Auf dem tatsächlichen Workshop-Gerät prüfen.

## 2. LM Studio installieren

### Windows

- 1 Offiziellen Installer von [lmstudio.ai](https://lmstudio.ai) laden.
- 2 Installieren und starten.
- 3 In Discover ein instruct-fähiges GGUF-Modell wählen.

### Linux

- 1 Aktuelles offizielles Linux-Paket laden.
- 2 Ausführbar machen oder distributionsgerecht installieren.
- 3 App starten und Modell laden.

Aktuelle Anforderungen: [LM Studio system requirements](#). Derzeit werden 16 GB RAM und 4 GB dedizierter VRAM empfohlen.

## 3. Modell auswählen

| Profil        | Startpunkt                | Typische Aufgabe                              |
|---------------|---------------------------|-----------------------------------------------|
| Sicher        | 3B–7B, Q4                 | Klassifikation, Zusammenfassung, Extraktion   |
| Ausgewogen    | 7B–14B, Q4                | Schreiben, einfache Analyse, begrenzte Tools  |
| Experimentell | größer / längerer Kontext | Nur wenn Speicher und Geschwindigkeit reichen |

Tool-Aufrufe separat testen: Ein gutes Chatmodell ist nicht automatisch ein guter Agentenmotor.

## 4. Local Server starten

- 1 Modell vollständig laden.
- 2 Developer-Bereich öffnen.
- 3 Local Server starten.
- 4 Adresse notieren, standardmäßig häufig `http://127.0.0.1:1234/v1`.

[Offizielle Server-Dokumentation](#)

## 5. Hermes verbinden

```
Provider type: OpenAI-compatible
Base URL: http://127.0.0.1:1234/v1
API key: lm-studio
Model: exakt der in LM Studio angezeigte Modellname
```

- ☐ Zuerst einfacher Chat-Test.
- ☐ Dann strukturierte Ausgabe testen.
- ☐ Erst danach Datei- oder Toolzugriff testen.
- ☐ Bei Fehlern Modellname, Serverstatus und URL prüfen.

## 6. Fairer Lokal-/Cloud-Test

```
Fasse das folgende fiktive Sitzungsprotokoll in genau 5 Punkten zusammen.
Extrahiere Entscheidungen und nächste Schritte als Markdown-Tabelle.
Erfinde nichts. Markiere fehlende Verantwortliche mit „nicht angegeben“.
Nenne am Ende zwei Unsicherheiten im Ausgangstext.
```

| Kriterium            | Lokal | Cloud |
|----------------------|-------|-------|
| Zeit bis zur Antwort |       |       |
| Korrekte Extraktion  |       |       |
| Format eingehalten   |       |       |
| Halluzinationen      |       |       |
| Datenschutz / Kosten |       |       |



# Sicherheit & Troubleshooting

Praktische Leitplanken für einen kontrollierten Einstieg.

## Freigabe-Ampel

### ● **Automatisch**

Lesen, suchen, analysieren,  
Entwürfe, Testdateien im  
Workshop-Ordner.

### ● **Bestätigen**

Dateien ändern, API-  
Aufrufe, Kalenderentwürfe,  
neue Connectoren.

### ● **Mensch entscheidet**

Senden, veröffentlichen,  
bezahlen, löschen,  
Berechtigungen erweitern.

## Datenklassen

| Klasse      | Beispiel                          | Empfehlung                                         |
|-------------|-----------------------------------|----------------------------------------------------|
| Öffentlich  | Webseiten, veröffentlichte Texte  | Cloud oder lokal                                   |
| Intern      | Projekte, Prozesse                | Genehmigte Cloud oder lokal                        |
| Vertraulich | Kunden-, Personal-, Vertragsdaten | Nur freigegebene Umgebung; möglichst lokal         |
| Geheimnis   | Passwörter, Tokens, Schlüssel     | Nicht in Prompt, Soul oder Dokumentation speichern |

# Fehlerbilder

| Problem                             | Prüfen                                                                                    |
|-------------------------------------|-------------------------------------------------------------------------------------------|
| Hermes antwortet nicht              | Provider-Login, Modellwahl, Internet, Rate Limit.                                         |
| LM Studio nicht erreichbar          | Modell geladen, Server läuft, URL/Port korrekt, Firewall lokal.                           |
| Tools funktionieren lokal schlecht  | Modell unterstützt Tool Calling? Kleiner Test mit einem Tool.                             |
| SOUL.md wird nicht gelesen          | Dateipfad und UTF-8-Codierung prüfen; keine ANSI-/Legacy-Codierung.                       |
| Port 4173 belegt                    | Der Workshop-Server wählt automatisch den nächsten freien Port. Terminalausgabe beachten. |
| Android erreicht Präsentation nicht | <code>npm run start:lan</code> , gleiches WLAN, Windows-Firewall, angezeigte LAN-IP.      |

## Im Zweifel stoppen

Wenn Ziel, Datenquelle, Berechtigung oder Auswirkung unklar ist: Agentenlauf stoppen, Vorschau prüfen und eine engere Aufgabe formulieren.